

Relatório 04 - Prática: Principais Bibliotecas e Ferramentas Python para Aprendizado de Máquina (I)

Gabriel Oliveira Santos


1. Introdução

O objetivo desta aula foi compreender o uso de Jupyter, NumPy e Pandas, ferramentas fundamentais para análise de dados e aprendizado de máquina. A tarefa consistiu em assistir às aulas, absorver os conceitos, extrair exemplos de código e montar um notebook próprio, validando na prática os conhecimentos adquiridos. O resultado esperado era consolidar a base para manipulação de dados, cálculos e organização dos dados.

2. Desenvolvimento


Tudo começa com o Jupyter, onde entendi que ele não era uma biblioteca, mas sim um ambiente de desenvolvimento, assim como o Colab da google. Ele permite escrever células de código, o que em minha visão facilita para visualização, organização e entendimento do código, rodando cada parte sozinha. Ele tem como ser instalado e rodado na máquina, como uma espécie de IDE.

Dentro dele, o python que roda possui algumas bibliotecas já integradas, como a Numpy. Essa biblioteca possui muitas utilidades, principalmente quando se fala de array, conteúdo majoritariamente apresentado nas aulas. Existem funções como:



- np.array – que cria arrays de várias dimensões
- np.arange – a que mais me chamou atenção, pois gera números aleatórios
- np.mean – gera a media dos valores, estatísticas básicas
- np.sum – soma todos os elementos do mesmo grupo no array, não sendo a única que faz operação, tem o np.sqrt, np.exp...
- np.min e np.max – respectivamente, mostram o menor e maior valor do array
- etc.

A np.arange funciona basicamente como um looping, que conta com espaço, início e fim. Ao chamar esse método, há como passar esses dados, e o fluxo fica basicamente assim:



Ou seja, é um fluxo básico, se começou, verifica o passo, se for 0 encerra pois não tem passo, se não, incrementa no tamanho do passo, depois verifica se precisa de mais, aí repete se sim, se não, encerra.

O Pandas é parecido, mas os comandos estão mais focados em DataFrames, conjuntos de dados, uma, duas ou mais dimensões, que vem a partir de um dicionário. Basicamente é uma tabela organizada.

Essa biblioteca também possui comandos de operações matemáticas, filtros, e preenchimento, como:

- `df['Nota'].mean()` – Media das notas [uma coluna] no dataframe.
- `df.corr()` – Correlação, de longe na minha visão, o mais útil para estatística.
- `df.fillna` e `df.dropna` - tratam valores nulos.
- `df.merge` - junta tabelas por chave.
- `df.groupby` - agrupa dados e aplica funções.
- etc

Nome das colunas

	A	B	C	D	A	B	C	D	A	B	C	D
0	A0	B0	C0	D0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	A1	B1	C1	D1	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	A2	B2	C2	D2	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	A3	B3	C3	D3	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	NaN	NaN	NaN	NaN	A4	B4	C4	D4	NaN	NaN	NaN	NaN
5	NaN	NaN	NaN	NaN	A5	B5	C5	D5	NaN	NaN	NaN	NaN
6	NaN	NaN	NaN	NaN	A6	B6	C6	D6	NaN	NaN	NaN	NaN
7	NaN	NaN	NaN	NaN	A7	B7	C7	D7	NaN	NaN	NaN	NaN
8	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	A8	B8	C8	D8
9	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	A9	B9	C9	D9
10	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	A10	B10	C10	D10
11	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	A11	B11	C11	D11

Dados faltantes

Index

Diferentemente da Numpy, Pandas consegue tratar dados externos, como ler arquivos .csv, excel, .txt... Isso favorece o tratamento dos dados, o que é útil para quando quer extrair de algum site muito grande, o filtro do Pandas é perfeito pra isso.

No geral, todas as bibliotecas acima apresentadas demonstram uma coisa apenas: O Python é mais do que uma linguagem, é uma ferramenta poderosa se usada corretamente, seja para ML, estatística ou operações básicas, ela serve para todos.

3. Conclusão

A conclusão sobre o meu aprendizado de Jupyter, NumPy e Pandas é que essas três ferramentas formam a base prática da análise de dados em Python. O Jupyter fornece o ambiente simples que permite visualizar cada etapa, o NumPy garante cálculos matemáticos rápidos em arrays e matrizes, e por fim, Pandas oferece estruturas de tabelas para manipulação, limpeza, agregação e exportação de dados.