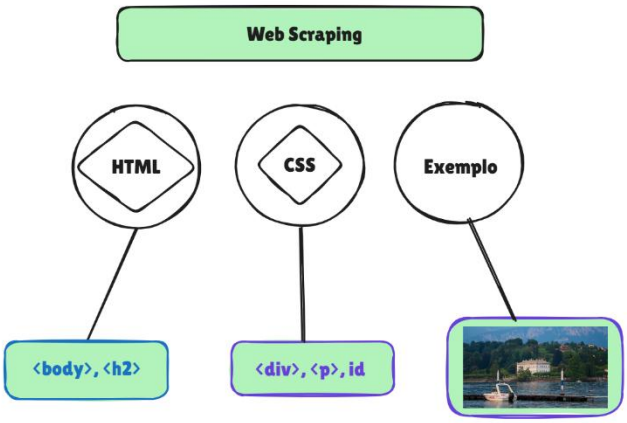
Relatório 8 - Prática: Web Scraping com Python p/ Ciência de Dados (II)

Gabriel Oliveira Santos

1. Introdução

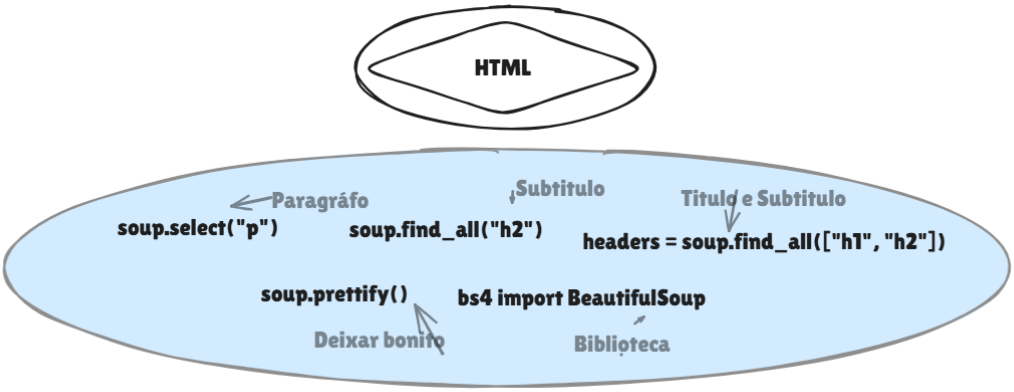
O objetivo desta aula foi compreender os fundamentos do Web Scraping e a extração automatizada de dados da web. Para isso, foram apresentados conceitos e exemplos práticos utilizando as bibliotecas Requests e BeautifulSoup, demonstrando técnicas de navegação e coleta de informações em páginas HTML

2. Desenvolvimento

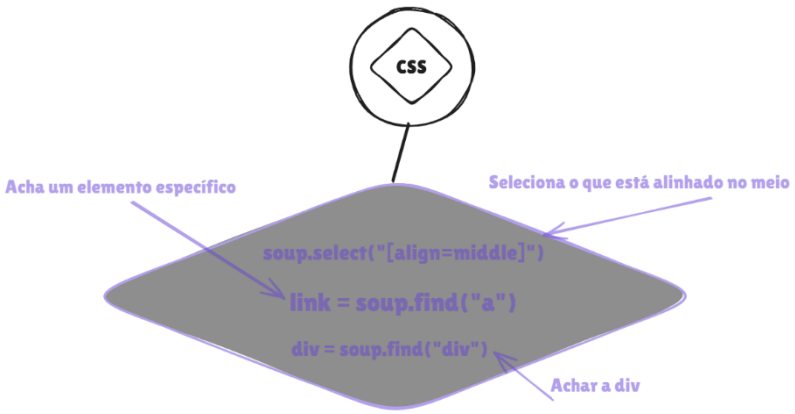


A aula apresenta o que é o Web Scraping, que significa “raspagem”, mas no nosso contexto de computação, é o processo de extração dos dados a partir da web de uma forma automatizada. O vídeo começa com conceitos simples e no fim são feitos 5 exercícios, apresentando em cada um uma parte do conteúdo apresentado.

- Primeiros passos: foi carregar as bibliotecas necessárias para fazer esse Web Scraping. Foram usadas duas bibliotecas como padrão, a requests e a BeautifulSoup.
    - Request – pega os dados HTML
    - BeautifulSoup – O atalho e funções que utilizamos o tempo todo

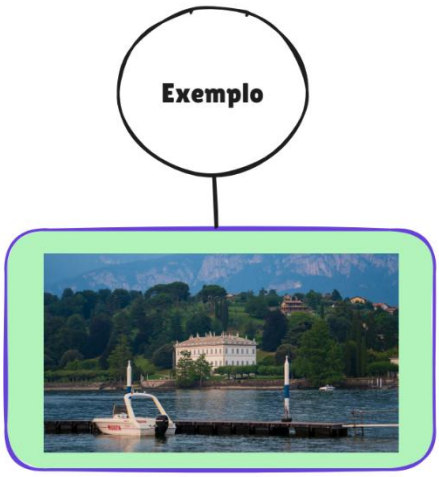


- Posteriormente os conteúdos:
  - A primeira coisa a fazer é carregar a URL. No vídeo usamos um projeto pessoal do professor, que foi desenvolvido durante a época da faculdade. O código extraído pode ser apresentado, de forma bonita e visível com a função prettify().
  - A Soup serviu para extrair e apresentar cada tag HTML, como a <h2>, que é um subtítulo. Ao todo, o HTML tem 6 tipos de cabeçalhos.
  - Há como também achar todos os parágrafos e ir filtrando por um específico, o qual é desejado. Essa função é interessante pois as vezes o site está bloqueado para copiar um dado, mas o dado está no html, sendo assim possível coletar esse parágrafo. Ex: soup.find_all(“p”) – encontra todos.
  - Mas ter o retorno de todos as vezes não é interessante, por isso há como ir filtrando como procurar pelas chaves principais do html, as ‘id’
  - Outra coisa que me chamou a atenção – Achar palavras específicas dentro do corpo html. Isso é muito útil para descobrir ‘chaves secretas’ assim como no último exercício. Diversas palavras durante o vídeo pudemos achar. Outra coisa que gostei foi filtrar por maiúsculas e minúsculas com esse símbolo e as letras: (C|c).



- O seletor CSS também funciona de forma similar, com a mesma biblioteca anterior, podendo encontrar o corpo, texto, as divs... Tudo que há no CSS e HTML. Mas de fato o que é diferencial é a busca por elementos em negrito.

- Outros elementos dentro dessas propriedades do html também podem ser raspados/extraídos.
- Busca por navegação de código também funciona, assim como no JAVA ou qualquer outra linguagem orientada a objetos, a busca por classes funciona da mesma forma no Web Scraping, podendo achar elementos assim: soup.body.div.h1.string
- Essa busca permite encontrar os parentes mais próximos, dado como irmãos, primos, pais...
- Nos exercícios, foi utilizada todas essas funções acima. Então podemos pelo exemplo do professor, buscar os links de rede social, descrever e organizar uma tabela que estava no HTML de exemplo, agregar e colocar ela em um DataFrame usando a biblioteca pandas, organizar as colunas e o exercício que mais me chamou a atenção.
- Ele consistia em achar a chave secreta dentro de uma parte do site. Fiquei me perguntando o como seria feito e me surpreendi com o como foi simples. Basicamente carregou a url da página com a chave secreta, mas estava bagunçada, e fomos filtrando com o que já havia sido mostrado na aula
    - O filtro usado foi uma sacada genial, colocamos o “id” como referencia pra buscar e a palavra “secret-word”, o que varreu a página e deu a chave, mas foi necessário filtrar para aparecer apenas o que queria, com um .string no final, a resposta finalmente veio.



3. Conclusão

Nessa aula pude aprofundar meus conhecimentos sobre HTML, CSS e Web Scraping, entendendo melhor como funciona a extração automática de dados de sites. Os conteúdos apresentados mostraram como localizar, filtrar e organizar informações específicas dentro de uma página. É uma ferramenta muito útil para a Ciência de Dados, pois facilita a coleta e o tratamento de grandes volumes de informação, permitindo obter apenas os dados necessários de forma rápida e prática, incluindo imagens.